


МОДУЛЬ ЗАЩИТЫ ПЕРСОНАЛЬНЫХ ДАННЫХ

Данные работают. *Личное остаётся личным.*

Локальная защита перед LLM.

Обратимость. Контекст. Проверяемые результаты.



Удачная основа. Чёткие границы роста.

Сильный демо-прокси; для пилота важнее закрыть измеримые пробелы, чем добавлять сервисы.

01 / РАЗДЕЛЕНИЕ

Логика по границам

API и правила — отдельно от NER.
Хранилище — вне модели.
LLM вызывает потребитель.
Профили можно менять явно.

02 / КОНТРОЛЬ

Прозрачные решения

Политика на потребителя.
Причины и Unicode-диапазоны.
Ошибка NER не скрывается.
Восстановление проверяется.

03 / ОГРАНИЧЕНИЯ

Нужен следующий шаг


NER ограничивает GPU-профиль.
Границы сущностей неточны.
Golden уже изучен разработкой.
НА задана конфигурацией,
но не доказывает zero-RPO.

ВЕРДИКТ

Развивать текущую модульную схему и измерять каждое изменение.

Защита данных до обращения к LLM


Путь нового payload_id. Повтор исходного запроса может вернуть сохранённый результат.



Политика выбирает, какие сущности защищать. Качество детектора определяет полноту маскирования.

Обратимость без передачи таблицы замен в LLM


Token-режим: восстановление ответа разрешает политика системы, а соответствия живут до истечения TTL.



Срок истёк → 410. Неизвестный или повреждённый токен не восстанавливается; ошибка детекции остаётся риском.

Детекция: правила и RuBERT в одном контракте


Экспериментальный GPU-профиль · исходные Unicode-координаты сохраняются до самой замены.



Одна и та же политика на всех датасетах. NER дополняет правила; числовые и контекстные проверки сохраняются.

Один сервис. Несколько профилей размещения.

Базовый Compose и подготовленные Kubernetes-манифесты. GPU-профиль подключается отдельно.



Репликация Redis асинхронная: последние записи могут быть потеряны при сбое. HA требует проверки в кластере.

Политика задаёт смысл защиты.

01 / ДОСТУП

Система-потребитель

Ключи, allowlist и отдельное разрешение unmask.
Демо-режим отделён от ограниченного режима.

02 / ПРАВИЛА

Настройка без правки ядра

Типы ПД, комбинации и custom rules.
Публичный контекст не равен личным данным.

03 / ДАННЫЕ

Шифрованное соответствие

AES-GCM и TTL для записей восстановления.
Namespace потребителя + payload_id.
Общий мастер-ключ нужен всем репликам.

04 / НАБЛЮДАЕМОСТЬ

Метрики без исходного текста

Этапы, длительность, типы и ошибки.
Захват raw-запросов — отдельная опция:
нужны свой retention и контроль доступа.

Кандидаты проверяли на трёх корпусах.

Текущие правила: spaCy, GLiNER, новый RuBERT. LFM и прежний RuBERT — исторические профили.

СЕРВИСНЫЙ ПРОФИЛЬ	ORGANIZER	PII-BENCH	REDMADROBOT	КОНТРАКТ
spaCy ru_core_news_sm	96,89	74,40	65,37	PERSON / LOC
GLiNER 2.5 / PyTorch	97,46	74,29	70,47	PERSON / LOC
GLiNER 2.5 / ONNX	97,46	74,29	70,47	PERSON / LOC
LFM2.5 / address-proxy	94,58	70,86	53,66	PERSON / LOC
RuBERT / прежний сервис	96,88	74,07	69,71	PERSON / LOC
RuBERT / текущий сервис	97,13	77,86	93,90	14 типов

LFM native hybrid: PII-Bench 84,18% — 40 типов, без правил СЕЙФ; отдельный профиль.
GLiNER пересчитан по сохранённым предсказаниям. Полный набор PII-классов требует нового inference.
446 / 1 810 / 2 839 текстов. Разные контракты и версии правил; это не рейтинг одних только моделей.


Обновление RuBERT улучшило маскирование.

Предыдущий RuBERT → текущий RuBERT → контроль pii-guard на исходном тексте.


Organizer

446 · AI silver

Раньше 96,88%



Сейчас 97,13%



pii-guard* 81,81%




Шкала: 0–100%


PII-Bench

1 810

Раньше 74,07%



Сейчас 77,86%



pii-guard* 78,55%




Шкала: 0–100%


RedMadRobot

2 839

Раньше 69,71%



Сейчас 93,90%



pii-guard* 93,67%



Шкала: 0–100%

* Правила + модель + merge без полного препроцессинга. Organizer — предварительная AI-разметка.

Скрыть символы $\neq$ точно выделить сущность.

RedMadRobot · * pii-guard: правила + модель + merge без полного препроцессинга.

F1 МАСКИРОВАНИЯ

93,90%

pii-guard*: 93,67%

EXACT F1 · COMMON14

86,76%

pii-guard*: 89,85%

Оставшиеся 801 несовпадение exact-span

386

Иные границы,
нужные символы скрыты

60

Другая категория,
символы скрыты

91

Защищены
частично

264

Размеченные сущности
не защищены

Скорость измеряли полным HTTP-циклом.

Два протокола — сравнения внутри каждой пары. Все значения ниже — успешные mask RPS.

GLiNER 2.5

Исторический сервис · 446 запросов · C4

PyTorch 31,89

ONNX 49,86

Шкала: 0-60 RPS

RuBERT TensorRT

22 300 запросов · C8 · 50 циклов

Прежний 528,86

Текущий 533,74

Шкала: 0-600 RPS

19,58 мс

p95 текущего RuBERT

0 / 22 300

ошибок HTTP / запросов

+0,92%

наблюдаемая разница RPS

Четыре риска, которые стоит закрыть.

P1 / РЕСУРСЫ

Допуск до затрат

Раннее отклонение чужих запросов.
Лимиты до чтения и разбора тела.

P1 / NER

Очередь по модели

Ограниченная очередь и backpressure.
Масштабирование по очереди/latency.

P1 / ДАННЫЕ

RPO и срок жизни

Проверить failover и повторы запросов.
Определить допустимую потерю записей.

P1 / CAPTURE

Отдельное хранение raw

Шифрование, retention и права доступа.
Убедиться, что capture отключён в пилоте.

Следующий шаг — измеримый пилот.

01 / КАЧЕСТВО

Независимая проверка

Holdout с ручной разметкой.
Mask F1, exact F1, recall типов.
Отдельная проверка РФ и СНГ.
Сборка ФИО для synthetic.

02 / СКОРОСТЬ

GPU-профиль под нагрузкой

Длинные тексты, mixed workload.
Очередь и batching — абляции.
p95 / p99 и доля ошибок.
Повторные прогоны без кэша.

03 / ПИЛОТ

Рабочий контур и эксплуатация

Секреты, ingress/TLS и права.
Retention capture и rotation ключей.
Восстановление после сбоев.
SLO и владелец реакции на ошибки.

Критерий успеха: качество, обратимость и latency сохраняются на новых данных и при отказах.

Демо на две минуты: видно каждое решение.

01

ПОДАТЬ ТЕКСТ

Личное рядом с публичным

02

ЗАЩИТИТЬ

Показать найденные типы

03

ВОССТАНОВИТЬ

Сверить точное
совпадение

04

ИЗМЕНИТЬ ПОЛИТИКУ

Показать управляемость

ИСХОДНЫЙ ТЕКСТ

Поэт Александр Пушкин.

Клиент: Иванов Иван Иванович.

ИЗМЕНИЛАСЬ ТОЛЬКО ЛИЧНАЯ ЧАСТЬ

Поэт Александр Пушкин.

Клиент: `[[PD:PERSON:...]]`

На экране: реальные типы, длительность, режим и результат восстановления.

Сильнее становится вся цепочка.

Управляемая защита.

Обратимый результат.

Проверяемый прогресс.

Фокус следующей итерации

Точные границы и типы на новых данных.

Скорость и восстановление при реальных ограничениях.

5 095

текстов в общем сравнении

533,74

RPS в финальном GPU-прогоне

3 119

прошедших основных тестов

Как проверять цифры этой презентации.

01 / ВЫБОРКА

5 095 фиксированных текстов

446 organizer: 329 certain + 117 uncertain.

1 810 PII-Bench; 2 839 RedMadRobot.

Два старых исключения выравнивания RMR.

02 / МЕТРИКИ

Сравниваем одинаковое с одинаковым

Mask F1 — закрытые буквы и цифры.

Exact F1 — тип и исходные границы.

Model texts/s не равны HTTP RPS.

Ключевые отчёты

`rubert-upgrade/quality-v5.json`

`rubert-upgrade/http-upgraded-final.json`

`gliner25-onnx/comparison-gpu.json`

`lfm25-pii/comparison.json`

Условия вывода

Organizer — AI silver, не официальный эталон.

Корпуса уже изучались: это не blind holdout.

pii-guard — raw-text ablation, не весь pipeline.

Kubernetes-конфигурация ≠ проверенный SLA.